Taller 11: Máquinas de Soporte Vectorial

Inteligencia Artificial – ELP 8012 – Universidad del Norte Profesor: Eduardo Zu
Ph.D.

Integrantes:

- Bryan Montoya
- Andrea Quintero
- Wilmer Santiago

Objetivo

Diseñar e implementar una Máquina de Soporte Vectorial (SVM) que clasifique los dí
escritos a mano del dataset `digits` de scikit-learn, encontrar el tipo de kernel con
desempeño usando validación cruzada k-fold y comparar los resultados con los talle
(Naive Bayes) y 10 (redes neuronales).

Metodología

1. Carga y exploración del dataset.
2. División estratificada 80 % entrenamiento / 20 % prueba (misma partición que e
   9).
3. Comparación de los kernels `linear`, `poly`, `rbf` y `sigmoid` con
   `StratifiedKFold(k=4)` sobre el 80 % de entrenamiento (se reporta media y
   desviación estándar).
4. Búsqueda de hiperparámetros (`C`, `gamma`, `degree`) del mejor kernel con k-fold
5. Evaluación final sobre el 20 % de prueba y comparación con los talleres 9 y 10.

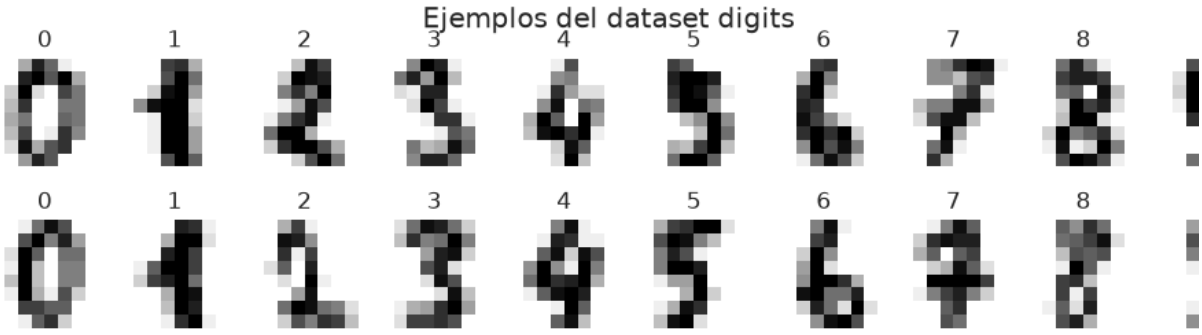
In [1]:
```
import time, warnings
import numpy as np, pandas as pd
import matplotlib.pyplot as plt, seaborn as sns
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split, StratifiedKFold, c
ross_validate, GridSearchCV
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import (accuracy_score, precision_score, recall_sc
ore, f1_score,
                             classification_report, ConfusionMatrixDisp
lay)
warnings.filterwarnings('ignore'); sns.set_theme(style='whitegrid')
SEED=42; K=4
```

1. Carga y exploración del dataset

`digits` contiene 1 797 imágenes de 8×8 píxeles (64 características con valores en 16) y 10 clases.

In [2]:
```
digits = load_digits()
X, y = digits.data, digits.target
print('X:', X.shape, '| y:', y.shape, '| clases:', np.unique(y))
print('Rango de píxeles:', X.min(), '-', X.max())
print('Muestras por clase:', np.bincount(y))
fig, axs = plt.subplots(2, 10, figsize=(12, 2.8))
for ax, img, lab in zip(axs.ravel(), digits.images, y):
    ax.imshow(img, cmap='gray_r'); ax.set_title(lab); ax.axis('off')
plt.suptitle('Ejemplos del dataset digits'); plt.show()
```

```
X: (1797, 64) | y: (1797,) | clases: [0 1 2 3 4 5 6 7 8 9]
Rango de píxeles: 0.0 - 16.0
Muestras por clase: [178 182 177 183 181 182 181 179 174 180]
```



2. División 80 % entrenamiento / 20 % prueba

División estratificada con `random_state=42`. El conjunto de prueba no se usa hasta evaluación final.

In [3]:
```
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.2,
stratify=y, random_state=SEED)
print('Entrenamiento:', X_tr.shape, '| Prueba:', X_te.shape)
```

```
Entrenamiento: (1437, 64) | Prueba: (360, 64)
```

3. Comparación de kernels con k-fold (k = 4)

Las SVM son sensibles a la escala, por eso se usa un `Pipeline` con `StandardScale` ajusta dentro de cada fold para evitar fuga de datos). Se prueban los cuatro kernels hiperparámetros por defecto (`C=1` , `gamma='scale'` , `degree=3`).

In [4]:
```
skf = StratifiedKFold(n_splits=K, shuffle=True, random_state=SEED)
scoring =
{'accuracy':'accuracy','precision':'precision_macro','recall':'recall_m
acro','f1':'f1_macro'}
rows=[]
for kern in ['linear','poly','rbf','sigmoid']:
    pipe = make_pipeline(StandardScaler(), SVC(kernel=kern,
```

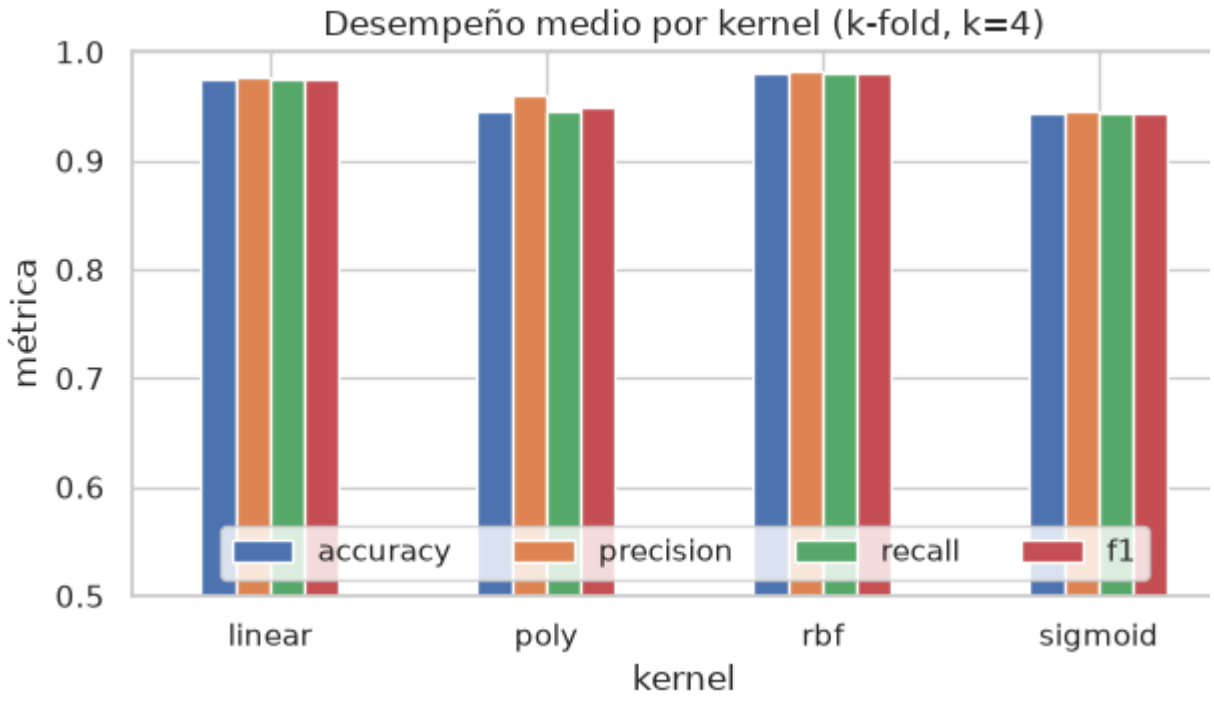
```
random_state=SEED))
    r = cross_validate(pipe, X_tr, y_tr, cv=skf, scoring=scoring, retur
n_train_score=True)
    rows.append({'kernel':kern,
        'accuracy':r['test_accuracy'].mean(), 'acc_std':r['test_accuracy
'].std(),
        'precision':r['test_precision'].mean(),
'recall':r['test_recall'].mean(),
        'f1':r['test_f1'].mean(), 'acc_train':r['train_accuracy'].mean()
,
        'fit_time_s':r['fit_time'].mean()})
res = pd.DataFrame(rows).set_index('kernel').round(4)
print(f'Resultados con StratifiedKFold(k={K}) sobre el conjunto de
entrenamiento')
display(res)
best_kernel = res['accuracy'].idxmax()
print('Mejor kernel por accuracy medio de validación:', best_kernel)
```

Resultados con StratifiedKFold(k=4) sobre el conjunto de entrenamiento

kernel	accuracy	acc_std	precision	recall	f1	acc_train	fit_time_s
linear	0.9756	0.0075	0.9763	0.9754	0.9754	1.0000	0.0158
poly	0.9457	0.0063	0.9599	0.9459	0.9482	0.9745	0.0322
rbf	0.9812	0.0093	0.9815	0.9811	0.9811	0.9974	0.0280
sigmoid	0.9436	0.0023	0.9452	0.9435	0.9432	0.9573	0.0230

Mejor kernel por accuracy medio de validación: rbf

In [5]:
```
ax = res[['accuracy','precision','recall','f1']].plot(kind='bar', figsi
ze=(6.5,3.8), ylim=(0.5,1.0))
ax.set_title('Desempeño medio por kernel (k-fold, k=4)');
ax.set_ylabel('métrica'); plt.xticks(rotation=0); plt.legend(loc='lower
center', ncol=4); plt.tight_layout(); plt.show()
```



4. Ajuste de hiperparámetros del mejor kernel

Se hace `GridSearchCV` con el mismo k-fold sobre el conjunto de entrenamiento par
kernel ganador, y también para `poly` (grado) como contraste.

In [6]:
```
grids = {
 'rbf':  {'svc__C':[0.1,1,10,100], 'svc__gamma':['scale',0.001,0.003,0.0
1,0.03]},
 'poly': {'svc__C':[0.1,1,10,100], 'svc__degree':[2,3,4], 'svc__gamma':
['scale',0.003,0.01]},
 'linear':{'svc__C':[0.001,0.01,0.1,1,10]},
 'sigmoid':{'svc__C':[0.1,1,10,100], 'svc__gamma':['scale',0.001,0.003,0
.01]},
}
tuned={}
for kern,g in grids.items():
    gs = GridSearchCV(make_pipeline(StandardScaler(), SVC(kernel=kern, r
andom_state=SEED)), g,
                      cv=skf, scoring='accuracy', n_jobs=-1)
    gs.fit(X_tr, y_tr); tuned[kern]=gs
    print(f'{kern:8s} mejor acc CV = {gs.best_score_:.4f} | {gs.best_pa
rams_}')
best_kernel = max(tuned, key=lambda k: tuned[k].best_score_)
print('\nKernel ganador tras ajuste:', best_kernel)
```

```
rbf      mejor acc CV = 0.9819 | {'svc__C': 10, 'svc__gamma': 'scale'}
poly     mejor acc CV = 0.9833 | {'svc__C': 100, 'svc__degree': 3, 'svc__gamm
'scale'}
linear   mejor acc CV = 0.9777 | {'svc__C': 0.1}
sigmoid  mejor acc CV = 0.9791 | {'svc__C': 10, 'svc__gamma': 0.003}

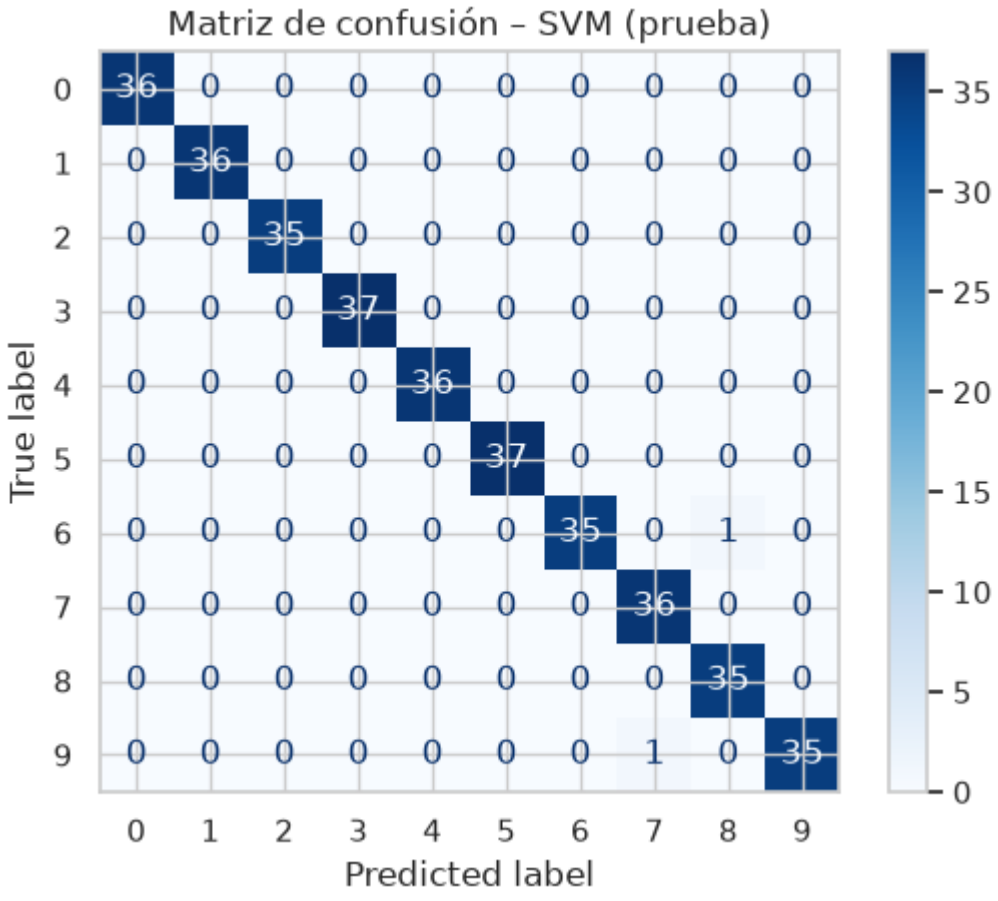
Kernel ganador tras ajuste: poly
```

5. Evaluación final en el conjunto de prueba (20 %

In [7]:
```
model = tuned[best_kernel].best_estimator_
t=time.time(); model.fit(X_tr, y_tr); fit_t=time.time()-t
y_pr = model.predict(X_te)
acc=accuracy_score(y_te,y_pr); pre=precision_score(y_te,y_pr,average='m
acro')
rec=recall_score(y_te,y_pr,average='macro'); f1=f1_score(y_te,y_pr,aver
age='macro')
print(f'SVM kernel={best_kernel} {tuned[best_kernel].best_params_}')
print(f'Accuracy: {acc:.4f}\nPrecision (macro): {pre:.4f}\nRecall
(macro): {rec:.4f}\nF1 (macro): {f1:.4f}')
print(f'Tiempo de entrenamiento: {fit_t:.3f}s | vectores de soporte: {m
odel[-1].n_support_.sum()} de {len(X_tr)}')
print(); print(classification_report(y_te, y_pr, digits=4))
ConfusionMatrixDisplay.from_predictions(y_te, y_pr, cmap='Blues'); plt.t
itle('Matriz de confusión — SVM (prueba)'); plt.show()
```

```
SVM kernel=poly {'svc__C': 100, 'svc__degree': 3, 'svc__gamma': 'scale'}
Accuracy: 0.9944
Precision (macro): 0.9945
Recall (macro): 0.9944
F1 (macro): 0.9944
Tiempo de entrenamiento: 0.050s | vectores de soporte: 649 de 1437
```

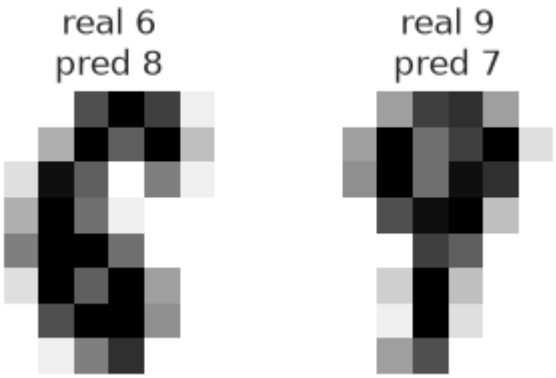
	precision	recall	f1-score	support
0	1.0000	1.0000	1.0000	36
1	1.0000	1.0000	1.0000	36
2	1.0000	1.0000	1.0000	35
3	1.0000	1.0000	1.0000	37
4	1.0000	1.0000	1.0000	36
5	1.0000	1.0000	1.0000	37
6	1.0000	0.9722	0.9859	36
7	0.9730	1.0000	0.9863	36
8	0.9722	1.0000	0.9859	35
9	1.0000	0.9722	0.9859	36
accuracy			0.9944	360
macro avg	0.9945	0.9944	0.9944	360
weighted avg	0.9946	0.9944	0.9944	360



In [8]:
```python
# Errores cometidos (evidencia)
err = np.where(y_pr!=y_te)[0]
print('Errores:', len(err), 'de', len(y_te))
if len(err):
    fig, axs = plt.subplots(1, len(err), figsize=(2*len(err), 2.4), squ
eeze=False)
    for ax,i in zip(axs[0],err):
        ax.imshow(X_te[i].reshape(8,8), cmap='gray_r'); ax.set_title(f'
```

```
real {y_te[i]}\npred {y_pr[i]}'); ax.axis('off')
    plt.show()
```

```
Errores: 2 de 360
```



In [9]:
```
# Rendimiento en prueba de los 4 kernels ya ajustados
rows=[]
for kern,gs in tuned.items():
    p=gs.best_estimator_.fit(X_tr,y_tr).predict(X_te)
    rows.append({'kernel':kern,'acc_CV':gs.best_score_,'acc_prueba':acc
uracy_score(y_te,p),
                 'f1_prueba':f1_score(y_te,p,average='macro'),'params':g
s.best_params_})
final=pd.DataFrame(rows).set_index('kernel'); final[['acc_CV','acc_prue
ba','f1_prueba']]=final[['acc_CV','acc_prueba','f1_prueba']].round(4)
display(final)
```

kernel	acc_CV	acc_prueba	f1_prueba	para
rbf	0.9819	0.9806	0.9805	{'svc__C': 10, 'svc__gamma': 'sca
poly	0.9833	0.9944	0.9944	{'svc__C': 100, 'svc__degree': 3, 'svc__gamm
linear	0.9777	0.9833	0.9831	{'svc__C':
sigmoid	0.9791	0.9806	0.9806	{'svc__C': 10, 'svc__gamma': 0.0

6. Comparación con los talleres 9 y 10

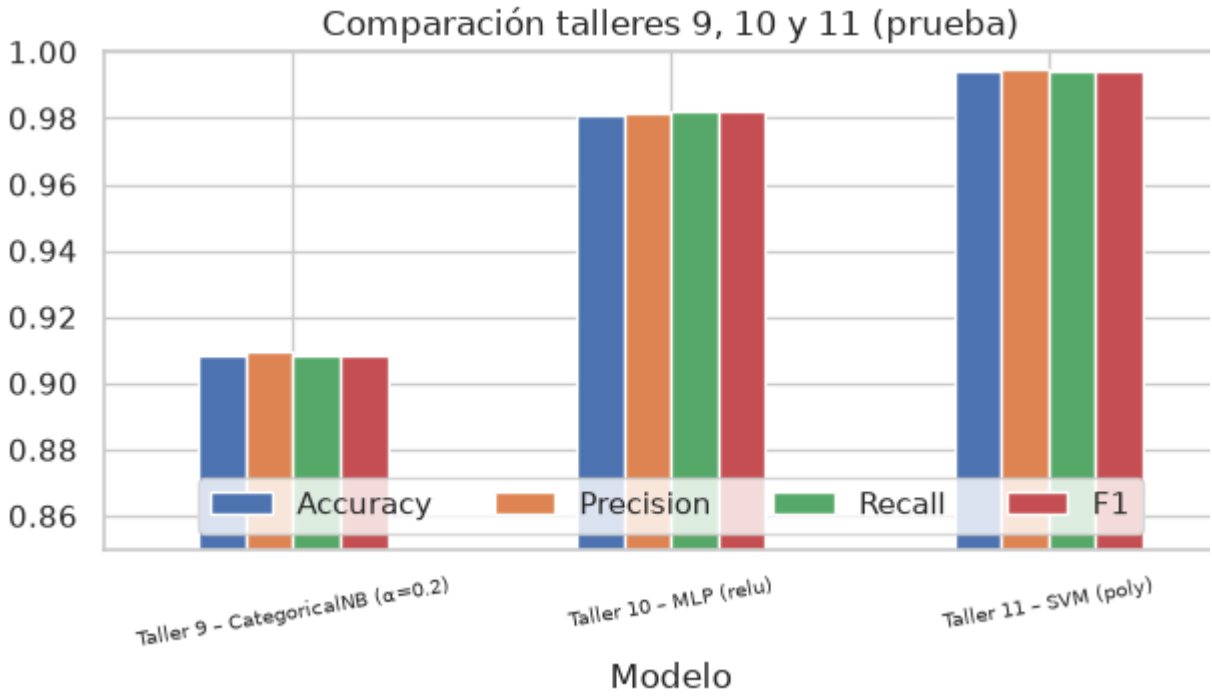
Resultados de los talleres anteriores (mismo dataset `digits`, 80/20 en ambos; valo copiados de los cuadernos entregados, sin reejecutar). **Nota:** el taller 9 usó la misma partición estratificada que este taller, pero el taller 10 usó otra partición (los soporte clase difieren), por lo que su comparación es aproximada:

- **Taller 9** – mejor clasificador bayesiano: `CategoricalNB`, α = 0,2.
- **Taller 10** – mejor red neuronal (MLP): activación `relu`.

In [10]:
```
comp = pd.DataFrame([
  {'Modelo':'Taller 9 — CategoricalNB (α=0.2)','Accuracy':0.9083,'Preci
sion':0.9094,'Recall':0.9081,'F1':0.9081},
  {'Modelo':'Taller 10 — MLP (relu)','Accuracy':0.9806,'Precision':0.981
7,'Recall':0.9820,'F1':0.9818},
  {'Modelo':f'Taller 11 — SVM ({best_kernel})','Accuracy':acc,'Precision
':pre,'Recall':rec,'F1':f1},
```

```
]).set_index('Modelo').round(4)
display(comp)
comp.plot(kind='bar', figsize=(6.5,3.8), ylim=(0.85,1.0)); plt.xticks(r
otation=10, fontsize=7); plt.legend(loc='lower center', ncol=4); plt.ti
tle('Comparación talleres 9, 10 y 11 (prueba)'); plt.tight_layout();
plt.show()
```

Modelo	Accuracy	Precision	Recall	F1
Taller 9 – CategoricalNB (α=0.2)	0.9083	0.9094	0.9081	0.9081
Taller 10 – MLP (relu)	0.9806	0.9817	0.9820	0.9818
Taller 11 – SVM (poly)	0.9944	0.9945	0.9944	0.9944



7. Análisis y conclusiones

Kernels (k-fold, k = 4, hiperparámetros por defecto): `rbf` 0,9812 > `linear` > `poly` 0,9457 > `sigmoid` 0,9436. Con valores por defecto el kernel RBF es el me

Tras ajustar `C`, `gamma` y `degree` con k-fold: `poly` (grado 3, C = 100) 0,9833, = 10) 0,9819, `sigmoid` 0,9791 y `linear` (C = 0,1) 0,9777. La diferencia entre `po` `rbf` (0,0014) es mucho menor que la desviación estándar entre folds (≈ 0,009), así **es estadísticamente concluyente**: ambos kernels no lineales son equivalentes en validación. Se selecciona `poly` por tener el mayor accuracy medio de validación, cr fijado antes de mirar el conjunto de prueba.

Prueba (20 %): el SVM `poly` obtiene accuracy 0,9944 (2 errores en 360), precisio 0,9945, recall 0,9944 y F1 0,9944. El modelo `rbf` ajustado obtiene 0,9806. Esta bre ~5 imágenes en 360 se debe en parte al azar de la partición, por eso la validación c es la medida más estable.

Observaciones:

- `digits` es casi linealmente separable (el kernel `linear` ya alcanza ≈ 0,98), pe kernels no lineales aportan un margen pequeño.
- Se estandariza con `StandardScaler` dentro de cada fold para evitar fuga de da SVM son sensibles a la escala.
- `C` controla el compromiso margen/sobreajuste; con `poly` un `C` alto (100) fue preferido. `sigmoid` con valores por defecto rinde mal y mejora solo al ajustar `g`
- Se usan 649 de 1 437 vectores de soporte (45 %).

Comparación con talleres anteriores: SVM (0,9944) > MLP relu del taller 10 (0,9 >> Naive Bayes categórico del taller 9 (0,9083). Naive Bayes asume independencia píxeles, lo que limita su desempeño. SVM y MLP están en el mismo rango (diferencia imágenes en 360, cada acierto vale 0,0028); la SVM es determinista y tarda ~0,05 s entrenar con pocos hiperparámetros.